

HACKING WORLD!

腾讯安全沙龙第9期 • 深圳站

→ 深圳南山文体中心聚橙剧院·小剧院

📅 07/04 ⌚ 13:30



生物黑客



金融黑客



社交黑客



身体黑客



物理黑客



思维黑客



碳硅互搏

从大脑 Hook 到碳基越狱

用 LLM 作为镜子，逆向我们自己的心智系统，
是时代给安全工程师最好的礼物



生物黑客



金融黑客



社交黑客



身体黑客



物理黑客



思维黑客

About Me

云鼎实验室 | 腾讯云安全

喻峰

> 独立安全研究员 Independent Security Researcher

曾任职于金山、网易、腾讯等公司，
从事过反病毒、游戏安全、云安全、威胁情报等工作

@ CORE_MODULES.EXE

AI / ML

Cloud Native

架构设计

技术管理

● SYS.ADMIN // ONLINE



你们每天都在对抗 *Hook*

但有没有想过

最深的 *Hook* 不在代码里

一次思想实验，一次不一样的逆向工程

目录

01

权限让渡

AI 怎样接管你的思考

02

模型转换

建一个碳基计算机模型

03

调试与机制

装上大脑调试器

04

结构和意义

看见即越狱

01 权限让渡

AI 怎样接管你的思考

从肌肉到大脑

三次技术替代浪潮

1st

体力外包

机械——肌肉力量被替代

2nd

重复性脑力外包

计算机——记忆和运算被替代

3rd

创造性脑力外包

生成式 AI——思考、判断和创造被替代

最后一次替代命中了你以为机器永远碰不到的东西

AI 的两面性

工具性

你在用 AI

- 提效、辅助、自动化
- 主进程可控
- 你是操作者

攻击性

AI 在用你

- Hook——大脑股权渗透
- 关键函数被 *detour*
- 你是被操控者

Hook 不可怕，可怕的是看不见 Hook
从员工到股东——AI 不断蚕食你的大脑股权

02 模型转换

先建一个碳基计算机模型



计算机

人类第一次接近造物主

- 复杂度
- 硬件+软件
- 输入输出系统
- 可编程



“我”是谁？



结论：“自我”只是这台机器 *Ring3* 的 *user* 用户，非 *root*。

“我”的权限

控制基本 API 接口

- 获取五官输入
- 分析、运算
- 控制身体输出

人类	计算机
醒来	登陆
看看周围	输入数据
起床活动	输出结果
学习	开发应用程序
工作	执行应用程序
睡觉	退出登陆

没有的权限

- 复杂身体控制权
 - 植物神经系统
 - 控制心跳、关闭听觉、加快消化、停止打嗝、起鸡皮疙瘩
 - 部分肌肉、筋膜控制权
- 情绪自主权
- 底层知情权
-

想要拿到 Ring0，先要见到 Ring0

感知 Ring0 ——呼吸实验

感知你的呼吸，发现会不由自主的控制它。

继续听讲，一分钟后再想起它。

你就完成了一次 Ring0 -> Ring3 -> Ring0 的一次切换。

呼吸是 R3 唯一可以随时接管的 R0 区域 [共享内存]

Root 可行性

绝大多数人的大脑是黑盒运行：

- 念头怎么产生？
- 情绪如何触发？
- 每个决策潜意识占比多少？——

全不可控，不可观测

源代码？

VS

调试器？

03 调试与机制

装上大脑调试器

止——中断



break OxBreath


把注意力锚定在呼吸等单一目标上

强制暂停自动化思绪〔静静〕

通过共享内存可以快速传递身体信号给 Ring0

知止而后有定

观——单步



不干预、不评判

观测念头的生起、停留、消散

从「我在焦虑」→「焦虑进程正在加载」

观察者：勿忘勿助

越界读写①呼吸

共享内存

Ring0 和 Ring3 共享区域

身体层

唯一可随时实时读写的接口

OxBreath

你的断点地址，第一个调试工具

意义

告诉内核“现在很安全，可以启动底层修复机制”

越界读写②情绪

重新定义

认知和事实不一致，产生的系统弹窗告警

自我层

认知逻辑连通 R0 与 R3 的信号通道

条件断点

寻找 Ring0 和 Ring3 的差异，我哪里搞错了？

意义

拆解情绪可读取 R0 原生客观感知、底层本能需求、固化的错误认知脚本；获得内核信任。

越界读写③梦境

重新定义

积压情绪的批量归档后台日志

内核层

白天被 R3 刻意屏蔽的原生感知事实

长期堆积、未修复的认知漏洞与情绪缓存碎片

R0 最原始的生存、安全感、归属等底层本能诉求

难度高

不求操纵梦境，醒后速记、睡前提问、情绪联动

意义

清理长期积压未处理的告警日志，和R0建立习惯性长连接




结构和意义

看见即越狱

Debug 模式：念头的形成

身体 + 自我 + 环境 = token上下文 -> 你下一个念头



身体

饥饿、疼痛、恐惧、疾病、求生……
比如虚弱的人难以做长线决策。
吾之大患，为吾有身。



自我

经历、知识、观念、思考、共识、情绪……
AI 可能正在成为自我的组成部分。



环境

空间、氛围、语言…
图书馆学习、西藏心胸开阔、老板喜欢顶
楼、开会场景、私密聊天……

Root 的洞见：清晰 token 生成上下文，哪些要摘除，哪些要加强。

建立审计防火墙

审计念头生成时的上下文 *Context*。

检查输入来源：

身体信号？ 经验烙印？ 环境注入？

还是 AI 植入的权重？

出厂缺失，需要你自己建设。

看见污染源 → 摘除污染 → 加固干净权重。

这就是心智系统的入侵检测。

攻击链和防御链

AI Hook 攻击路径

- AI Hook 劫持思考
- 本地推理退化
- 权重持续受到污染
- 自我模型被驯化
- 决策权主动移交

碳基 Root 防御路径

- 练习中断
- 单步调试
- 清晰三重权重
- 审计摘除污染上下文
- 削弱 AI 权重
- 守住 Ring0 内核主导权

Hook 不可怕，看不见 Hook 才可怕。
有没有 AI 一 犹如冷兵器和加特林。新的武器天然带巨大后座力。
建立符合生产力的新心智底座

R3 VS R0

轻松，但失控

- 被动推送情绪、决策信号，不知来处
- 反应模式
- 不知道自己被操控

看似累，极致清醒

- 看着念头来去
- 情绪自主，降低内耗
- 看见 Hook，安之若素

见过 root，才有的选。
碳基越狱，从来不是逃离硅基时代。
是在人机共生的世界里，坐稳自己人生的控股股东位置。

古老越狱指南

致虚极，
守静笃，
万物并作，
吾以观其复。

- 清空上下文栈，关掉多余后台进程
- 持续保持断点模式，稳定调试态
- 三层权重叠加，念头源源不断
- 站在 Ring0 视角，如如不动

——《道德经》

番外生物/神经黑客

类型	操作层级	核心动作	本质问题
生物黑客	R3 肉身层面	外力改造硬件参数, 增加外部接口	不改漏洞、只改数据、 透支稳态
神经黑客	R3 大脑前台	超频脑力算力	只提效率、不纠偏差、 堆积内耗
内核调试	R0+R3 双向	观测内核、对齐事实、 清理缓存	提升权限、审计输入, 保证控股权

THANKS



生物黑客



金融黑客



社交黑客



身体黑客



物理黑客



思维黑客